

5. Introdução ao Aprendizado de Representação e Redes Adversárias Generativas (Catarina)

5.1 Representação de Dados

5.2 Autoencoders & 5.3 Deep Autoencoders -> vou juntar

5.4 Autoencoders convolucionais

5.5 Autoencoders recorrentes

5.6 Autoencoders variacionais

5.7 De modelos discriminativos a generativos. Transferência de estilo

5.8 Redes adversárias generativas

Neural Style Transfer mostrar imagens



Style transfer Neural style transfer

Gan para gerar dígitos do mnist:

https://colab.research.google.com/drive/1yiWWoIXHSMfau_QwwChYv0lcxzjAHHeH

$$P_{\text{dados}}(x)$$

$$X$$

$$P(z)$$

$$Z$$

$$G(z)$$

$$D(x)$$

$$\min_G \max_D V(D, G)$$

$$V(D, G) = \mathbb{E}_{x \sim p_{\text{dados}}} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))]$$

$$V(D, G) = \mathbb{E}_x [\log D(x)] + \mathbb{E}_z [\log(1 - D(G(z)))]$$

$$H(X) := \mathbb{E}(-\log P(X)).$$

$$\frac{(n-k+2p)}{s}+1$$

$$w_{i,j} = tf_{i,j} \times \log \left(\frac{N}{df_i} \right)$$

$$\begin{aligned} tf_{ij} &= \text{number of occurrences of } i \text{ in } j \\ df_i &= \text{number of documents containing } i \\ N &= \text{total number of documents} \end{aligned}$$

$$w_{i,j} = t f_{i,j} \cdot \log \left(\frac{N}{df_i} \right)$$